报告与负载配置

导出时间：2026-11-02T10:08:08.511Z · PDF 包含页面全部指标及额外诊断明细

模型	theme-fixture-model
Phase	decode
PD Scenario	decode
Batch Size	16
P / D Batch Size	16 / 32
Input Length	8192
Output Length	256
Prefix Hit Ratio	0
MTP Tokens	6
MTP Ratio	0.85
MTP Tokens Candidates	6
MTP Ratio Candidates	0.85
World Size	8
TP / DP / PP	8 / 1 / 1
EP / EDP / ETP / CP	8 / 1 / 1 / 1
Embed TP	8
O TP	8
LMHead TP	8
优化模式	manual
目标 TTFT / TPOT	1000 / 20 ms

量化配置

全局	BF16
Attention	BF16
MLP	BF16
共享专家	BF16
路由专家	BF16
KV Cache	BF16
激活值	BF16

PD 网络与部署

PD Enabled（生效值 / 表单值）	false / false
KV Over ScaleOut	true
P / D Instances / Pairs	2 / 1 / 1
ScaleOut Bandwidth / Efficiency	50 GB/s / 0.75
Alpha / Concurrency	0 us / 1
Payload Scale / Exposed Ratio	1 / 1
P Nodes / Local Hit	1 / 0.2
Cross-P Prefix Transfer	true
P TTFT / D TPOT SLA	2000 / 30 ms

硬件配置

Theme A6

芯片	Theme A6
显存	80 GB
显存带宽	2000 GB/s
L2 缓存	0 MB
BWSIO / OS内 / SuperPod内 / SO 通信	0 / 600 / 100 / 0 GB/s
Cube / Vector / SFU / 显存效率	60.0% / 60.0% / 60.0% / 80.0%
机内 / 机间 / ScaleOut 通信效率	50.0% / 50.0% / 0.0%
L2 Cache 效率	0.0%
常驻噪声	5 GB
Cube / Vector / SFU Cores	0 / 0 / 0
Cube Frequency	0
FP16 Cube / Vector / SFU	0 / 0 / 0
BWSIO / OS / SuperPod Limit	0 / 0 / 0

算子级算力利用率覆盖（PDF 专有完整明细）

算子族	数据类型	利用率
No overrides		

仿真结果 · Theme A6

指标	值	说明 / 公式
TPOT	0.16 ms	
端到端生成时延	72.96 ms	
Decode 单卡 TPS	12500.00 tok/s/GPU	
Decode QPS	390.00 req/s	
总显存占用	48.00 GB	
OOM	未检出 OOM（证据未核查）	
显存证据	显存证据未核查	显存证据未核查，保留历史结果，容量可行性未确认。
并行策略	TP8 DP1 EP8 PP1 CP1	

仿真结果 · Theme A6 · 仿真元数据（PDF 专有）

指标	值	说明 / 公式
仿真时间戳	—	PDF 诊断项
起始时间	0	ns；PDF 诊断项
结束时间	0	ns；PDF 诊断项

Rank 统计 · Theme A6 · Decode

Rank	耗时	峰值显存	权重	通信 Buffer + 激活	噪声	容量	算子数	状态
Rank 0	0.16 ms	48.00 GB	24.00 GB	8.00 GB	0.00 GB	192.00 GB	3	未检出 OOM（证据未核查）

算子汇总 · Theme A6 · Decode

#	算子	调用次数	总耗时	平均耗时	占比
1	MatMul	1	80.0 us	80.0 us	50.0%
2	AllReduce	1	60.0 us	60.0 us	37.5%
3	RMSNorm	1	20.0 us	20.0 us	12.5%

算子详情 · Theme A6 · Decode

算子	层	Rank	Module	计算	访存	通信	启动/调度开销	总耗时	Bound	算子族	利用率	来源	开始(ns)	结束(ns)
RMSNorm	0	0	attention.rmsnorm	2.00	20.00	0.00	1.00	20.00	memory	—	—	—	0	80000
MatMul	0	0	attention.matmul	80.00	10.00	0.00	1.00	80.00	compute	—	—	—	80000	160000
AllReduce	0	0	attention.allreduce	2.00	10.00	60.00	1.00	60.00	communication	—	—	—	160000	240000

算子张量 · Theme A6 · Decode

算子	Inputs	Params	Outputs
RMSNorm	input: [16, 4096] BF16	—	output: [16, 1024] BF16
MatMul	input: [16, 4096] BF16	weight: [4096, 1024] BF16	output: [16, 1024] BF16
AllReduce	input: [16, 4096] BF16	—	output: [16, 1024] BF16