# 报告与负载配置

导出时间：2026-11-09T07:37:27.469Z · PDF 包含页面全部指标及额外诊断明细

| | |
|---|---|
| 模型 | theme-fixture-model |
| Phase | decode |
| PD Scenario | decode |
| Batch Size | 16 |
| P / D Batch Size | 16 / 32 |
| Input Length | 8192 |
| Output Length | 256 |
| Prefix Hit Ratio | 0 |
| MTP Tokens | 6 |
| MTP Ratio | 0.85 |
| MTP Tokens Candidates | 6 |
| MTP Ratio Candidates | 0.85 |
| World Size | 8 |
| TP / DP / PP | 8 / 1 / 1 |
| EP / EDP / ETP / CP | 8 / 1 / 1 / 1 |
| Embed TP | 8 |
| O TP | 8 |
| LMHead TP | 8 |
| 优化模式 | manual |
| 目标 TTFT / TPOT | 1000 / 20 ms |

## 量化配置

| | |
|---|---|
| 全局 | BF16 |
| Attention | BF16 |
| MLP | BF16 |
| 共享专家 | BF16 |
| 路由专家 | BF16 |
| KV Cache | BF16 |
| 激活值 | BF16 |

## PD 网络与部署

| | |
|---|---|
| PD Enabled（生效值 / 表单值） | false / false |
| KV Over ScaleOut | true |
| P / D Instances / Pairs | 2 / 1 / 1 |
| ScaleOut Bandwidth / Efficiency | 50 GB/s / 0.75 |
| Alpha / Concurrency | 0 us / 1 |
| Payload Scale / Exposed Ratio | 1 / 1 |
| P Nodes / Local Hit | 1 / 0.2 |
| Cross-P Prefix Transfer | true |
| P TTFT / D TPOT SLA | 2000 / 30 ms |

## 硬件配置

Theme A6

| | |
|---|---|
| 芯片 | Theme A6 |
| 显存 | 80 GB |
| 显存带宽 | 2000 GB/s |
| L2 缓存 | 0 MB |
| BWSIO / OS内 / SuperPod内 / SO 通信 | 0 / 600 / 100 / 0 GB/s |
| Cube / Vector / SFU / 显存效率 | 60.0% / 60.0% / 60.0% / 80.0% |
| 机内 / 机间 / ScaleOut 通信效率 | 50.0% / 50.0% / 0.0% |
| L2 Cache 效率 | 0.0% |
| 常驻噪声 | 5 GB |
| Cube / Vector / SFU Cores | 0 / 0 / 0 |
| Cube Frequency | 0 |
| FP16 Cube / Vector / SFU | 0 / 0 / 0 |
| BWSIO / OS / SuperPod Limit | 0 / 0 / 0 |

算子级算力利用率覆盖（PDF 专有完整明细）

| 算子族 | 数据类型 | 利用率 |
|---|---|---|
| No overrides | | |

## 仿真结果 · Theme A6

| 指标 | 值 | 说明 / 公式 |
|---|---|---|
| TPOT | 0.16 ms | |
| 端到端生成时延 | 72.96 ms | |
| Decode 单卡 TPS | 12500.00 tok/s/GPU | |
| Decode QPS | 390.00 req/s | |
| 总显存占用 | 48.00 GB | |
| OOM | 未检出 OOM（证据未核查） | |
| 显存证据 | 显存证据未核查 | 显存证据未核查，保留历史结果，容量可行性未确认。 |
| 并行策略 | TP8 DP1 EP8 PP1 CP1 | |

## 仿真结果 · Theme A6 · 仿真元数据（PDF 专有）

| 指标 | 值 | 说明 / 公式 |
|---|---|---|
| 仿真时间戳 | — | PDF 诊断项 |
| 起始时间 | 0 | ns；PDF 诊断项 |
| 结束时间 | 0 | ns；PDF 诊断项 |

## Rank 统计 · Theme A6 · Decode

| Rank | 耗时 | 峰值显存 | 权重 | 通信 Buffer + 激活 | 噪声 | 容量 | 算子数 | 状态 |
|---|---|---|---|---|---|---|---|---|
| Rank 0 | 0.16 ms | 48.00 GB | 24.00 GB | 8.00 GB | 0.00 GB | 192.00 GB | 3 | 未检出 OOM（证据未核查） |

## 算子汇总 · Theme A6 · Decode

| # | 算子 | 调用次数 | 总耗时 | 平均耗时 | 占比 |
|---|---|---|---|---|---|
| 1 | MatMul | 1 | 80.0 us | 80.0 us | 50.0% |
| 2 | AllReduce | 1 | 60.0 us | 60.0 us | 37.5% |
| 3 | RMSNorm | 1 | 20.0 us | 20.0 us | 12.5% |

## 算子详情 · Theme A6 · Decode

| 算子 | 层 | Rank | Module | 计算 | 访存 | 通信 | 启动/调度开销 | 总耗时 | Bound | 算子族 | 利用率 | 来源 | 开始(ns) | 结束(ns) |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| RMSNorm | 0 | 0 | attention.rmsnorm | 2.00 | 20.00 | 0.00 | 1.00 | 20.00 | memory | — | — | — | 0 | 80000 |
| MatMul | 0 | 0 | attention.matmul | 80.00 | 10.00 | 0.00 | 1.00 | 80.00 | compute | — | — | — | 80000 | 160000 |
| AllReduce | 0 | 0 | attention.allreduce | 2.00 | 10.00 | 60.00 | 1.00 | 60.00 | communication | — | — | — | 160000 | 240000 |

## 算子张量 · Theme A6 · Decode

| 算子 | Inputs | Params | Outputs |
|---|---|---|---|
| RMSNorm | input: [16, 4096] BF16 | — | output: [16, 1024] BF16 |
| MatMul | input: [16, 4096] BF16 | weight: [4096, 1024] BF16 | output: [16, 1024] BF16 |
| AllReduce | input: [16, 4096] BF16 | — | output: [16, 1024] BF16 |